Modeling Arbitrage Opportunities in Tri-Listed Stocks Through Event-Based Process Mining

Leonardo Pratelli*

University of Pisa and Scuola Superiore Sant'Anna

Abstract

Financial markets increasingly exhibit complex microstructural dynamics, especially for assets listed across multiple exchanges. Tri-listed stocks, traded simultaneously in different geographic and currency environments, provide a natural setting for the emergence of short-lived arbitrage opportunities due to price discrepancies, latency effects, and exchange-specific liquidity conditions. This paper proposes a novel framework that integrates high-frequency financial data with process mining techniques to analyze the lifecycle of arbitrage opportunities. By transforming market events into structured event logs, we model arbitrage episodes as processes composed of distinct phases, such as detection, spread expansion, execution, and convergence. Using tri-listed equities (e.g., Unilever) as a case study, we apply process discovery algorithms (e.g., Alpha algorithm and Petri nets) to uncover recurrent behavioral patterns in arbitrage formation and resolution. The approach enables the identification of dominant process variants, timing structures, and inefficiencies in market alignment across exchanges. The results demonstrate how process mining can provide a new lens for understanding financial market microstructure, offering insights into the temporal dynamics and structural patterns underlying arbitrage opportunities. This work contributes to bridging data science, financial economics, and process mining, opening new directions for the analysis of high-frequency trading phenomena.Vedi la modifica? Ora? Ora? Sì vedi la modifica, grazie!

1. Introduction

Introduction part...

2. Mathematical Framework

This section introduces the mathematical framework used to detect and evaluate cross-market arbitrage opportunities. The goal is to define, in a rigorous way, the variables and functions needed to identify an executable arbitrage spread, measure the associated risks, and determine the optimal trade size.

*l.pratelli3@studenti.unipi.it; s3l.pratelli@santannapisa.it

2.1 Price Normalization

Let $P_i^{(c_i)}(t)$ denote the price of the asset quoted on market i in local currency c_i. Since the same asset may be traded on different venues and in different currencies, all prices must first be converted into a common numeraire, here taken to be the euro. Therefore, the normalized price is defined as

$$P_i^{EUR}(t) = P_i^{(c_i)}(t) \cdot FX_{c_i \to EUR}(t),$$

where $FX_{c_i \to EUR}(t)$ is the exchange rate from currency c_i to EUR at time t.

This normalization step is essential: without expressing prices in the same currency, any comparison across markets would be economically meaningless.

2.2 Executable Arbitrage Spread

A simple price difference between two markets i and j can be written as

$$\Delta_{ij}(t) = P_i^{EUR}(t) - P_j^{EUR}(t).$$

However, this quantity alone is not sufficient for real arbitrage trading. In practice, one must account for the bid-ask structure of each market. If the strategy consists of selling on market i and buying on market j, then the executable gross arbitrage spread per unit is

$$g_{ij}(t) = Bid_i^{EUR}(t) - Ask_j^{EUR}(t).$$

This is the economically relevant quantity because the trader can only sell at the bid and buy at the ask. An executable arbitrage opportunity therefore exists only if

$$g_{ij}(t) > 0,$$

and, more realistically, only if this gross spread exceeds the relevant execution costs.

2.3 Transaction Costs

Let Q denote the traded quantity. The total transaction cost can be represented in general form as

$$C(Q) = Q\, c_{unit} + c_{fixed},$$

where:

- c_{unit} is the marginal cost per traded unit;
- c_{fixed} is the fixed cost of initiating the trade.

The term $Q\, c_{unit}$ captures all costs that increase proportionally with the size of the position, such as proportional fees or per-share charges. The fixed term c_{fixed} accounts for costs that are paid regardless of the trade size, such as ticket fees or fixed brokerage costs.

This linear-affine specification is a first approximation. In more realistic settings, market impact and slippage may generate convex costs, for instance

$$C(Q) = c_{fixed} + c_1 Q + c_2 Q^2,$$

with $c_2 > 0$. The quadratic term reflects the fact that larger orders are typically more expensive to execute.

2.4 Expected Profit

Given an executable gross spread $g_{ij}(t)$, the expected profit of a trade of size Q is

$$\Pi(Q,t) = Q\, g_{ij}(t) - C(Q).$$

Under the linear cost specification, this becomes

$$\Pi(Q,t) = Q\, g_{ij}(t) - Q\, c_{unit} - c_{fixed} = Q\big(g_{ij}(t) - c_{unit}\big) - c_{fixed}.$$

This immediately implies two necessary conditions for entering the trade:

$$g_{ij}(t) > c_{unit},$$

and

$$Q\big(g_{ij}(t) - c_{unit}\big) > c_{fixed}.$$

The second inequality can be rewritten as

$$Q > \frac{c_{fixed}}{g_{ij}(t) - c_{unit}},$$

which identifies the minimum economically meaningful trade size needed to cover fixed costs.

2.5 Liquidity Constraint

Even when an arbitrage spread exists, the executable trade size is bounded by the liquidity available at the best quotes. If the strategy buys on market j and sells on market i, then the maximum size executable without walking deeper into the order book is

$$Q_{book}(t) = \min\{AskSize_j(t),\, BidSize_i(t)\}.$$

This is a microstructural constraint, not a theoretical one. It ensures that the strategy is consistent with the quantities actually available at the best bid and ask levels.

2.6 Closing Risk

In an ideal frictionless arbitrage, both legs of the strategy would be executed simultaneously and the gain would be locked in immediately. In practice, however, execution may be asynchronous, partial, or delayed. As a consequence, there is a residual risk that the spread changes adversely before the position is fully established or closed. This is referred to as *closing risk*.

Let $X_{ij}(t)$ denote the relevant spread or mispricing process, for example

$$X_{ij}(t) = Bid_i^{EUR}(t) - Ask_j^{EUR}(t).$$

Assume that, locally in time, $X_{ij}(t)$ follows a diffusion-type dynamics:

$$dX_{ij}(t) = \mu_{ij}\, dt + \sigma_{ij}\, dW_t,$$

where μ_{ij} is the local drift and σ_{ij} is the instantaneous volatility of the cross-market spread.

Over a short horizon τ, the increment satisfies

$$X_{ij}(t+\tau) - X_{ij}(t) \sim \mathcal{N}(\mu_{ij}\tau, \sigma_{ij}^2\tau).$$

Therefore, the standard deviation of the spread change over the interval τ is

$$\sigma_{ij}\sqrt{\tau}.$$

If the exposure is proportional to the traded quantity Q, then a natural standard-deviation-based measure of monetary risk is

$$R(Q,\tau) = Q\,\sigma_{ij}\sqrt{\tau}.$$

This formula follows directly from the standard square-root-of-time scaling of diffusion processes. It is important to stress that the dependence on $\sqrt{\tau}$, and not on τ, arises because variance grows linearly in time while standard deviation grows with the square root of time.

A Value-at-Risk style version can also be introduced:

$$VaR_\alpha(Q,\tau) = z_\alpha\,Q\,\sigma_{ij}\sqrt{\tau},$$

where z_α is the appropriate standard normal quantile.

2.7 Optimal Trade Size

The optimal trade size should balance expected profit, execution costs, and risk. Let $m(t)$ denote the expected gross margin per unit, so that $m(t)$ can be identified with $g_{ij}(t)$ or with a corrected forecast of the tradable spread. A general optimization problem is

$$\max_{Q\geq 0}\Big(Q\,m(t) - C(Q) - \lambda\,R(Q,\tau)\Big),$$

where $\lambda > 0$ is a coefficient of risk aversion.

Using the convex cost specification

$$C(Q) = c_{fixed} + c_1 Q + c_2 Q^2$$

and the risk measure

$$R(Q,\tau) = Q\,\sigma_{ij}\sqrt{\tau},$$

the objective function becomes

$$\max_{Q\geq 0}\left[Q\,m(t) - c_{fixed} - c_1 Q - c_2 Q^2 - \lambda Q\sigma_{ij}\sqrt{\tau}\right].$$

Rearranging terms, one obtains

$$\max_{Q\geq 0}\left[-c_2 Q^2 + Q\big(m(t) - c_1 - \lambda\sigma_{ij}\sqrt{\tau}\big) - c_{fixed}\right].$$

The first-order condition yields

$$-2c_2 Q + m(t) - c_1 - \lambda\sigma_{ij}\sqrt{\tau} = 0,$$

hence the unconstrained optimal size is

$$Q^*(t) = \frac{m(t) - c_1 - \lambda\sigma_{ij}\sqrt{\tau}}{2c_2},$$

provided that the numerator is positive. Otherwise, the optimal choice is $Q^*(t) = 0$.

Finally, the executable size must respect all relevant constraints, including book liquidity, capital, and leverage. Therefore, the final implementable size is

$$Q^{exec}(t) = \min\{Q^*(t),\, Q_{book}(t),\, Q_{capital}(t),\, Q_{lev}(t)\}.$$

2.8 Short Selling and Relative Mispricing

In a cross-market arbitrage framework, short selling does not necessarily rely on the belief that the absolute price of the asset will decrease. Rather, it is justified by a *relative mispricing* across markets. If

$$Bid_i^{EUR}(t) > Ask_j^{EUR}(t),$$

then one can sell short on market i and buy on market j, exploiting the temporary inconsistency between the two venues.

However, this strategy is feasible only if short selling is operationally possible, borrowing costs are manageable, and the residual execution risk does not offset the expected gain. These considerations should therefore be incorporated into the total cost function $C(Q)$.

2.9 Process Mining Extension

Process mining can be used as a complementary layer to analyze the operational decision process underlying arbitrage execution. For example, one may define an event log with activities such as

$$\texttt{gap_detected} \to \texttt{liquidity_checked} \to \texttt{size_computed} \to \texttt{trade_executed} \to \texttt{position_closed}.$$

In this context, process mining is useful to identify recurring decision patterns, execution variants, delays, and bottlenecks. It may also help evaluate which decision sequences are associated with better outcomes.

However, the estimation of the optimal trade size itself remains primarily an optimization problem based on prices, liquidity, costs, and risk. Therefore, process mining should be interpreted as a supporting analytical layer rather than as the main mathematical engine for computing $Q^*(t)$.

2.10 The Mechanics of Modern Electronic Markets

Law part...

3. Conclusion

Something else...

4. Analisi dei Risultati di Simulazione

Questa sezione presenta un'analisi empirica dei risultati ottenuti attraverso il framework di simulazione, con particolare attenzione alla validazione statistica del modello, alle caratteristiche delle finestre di arbitraggio e alle performance economiche della strategia.

4.1 Validazione della Simulazione

La validazione è stata condotta confrontando le principali proprietà statistiche dei dati simulati con quelle osservate nel mercato reale. In particolare, sono state analizzate la volatilità dei rendimenti (ret_std) e lo spread medio (spread_mean).

I risultati mostrano che:

- Per i titoli UL e SHELL, la volatilità simulata risulta ben allineata a quella reale, indicando che il modello è in grado di riprodurre correttamente la dinamica dei prezzi a livello tick-by-tick.

- Per HSBC, la volatilità rimane sottostimata rispetto al reale (circa il 40% in meno). Questo è coerente con la natura dell'asset (ADR), la cui dinamica è influenzata da mercati non direttamente osservati (Hong Kong), difficili da replicare in assenza di dati reali.
- Lo spread medio simulato risulta molto vicino al reale, in particolare per la venue AMS, mentre per LSE si osserva una leggera sottostima (15%), attribuibile agli effetti di conversione valutaria.

Tuttavia, permane una criticità importante:

- La variabilità dello spread (spread_std) risulta ancora significativamente inferiore rispetto al mercato reale (circa un ordine di grandezza). Questo implica che la simulazione genera condizioni di mercato più stabili rispetto alla realtà, riducendo la presenza di picchi di liquidità e disallineamenti improvvisi.

Questo limite suggerisce che, pur essendo corretta in termini di primi momenti statistici, la simulazione non cattura completamente la microstruttura del mercato.

4.2 Finestre di Arbitraggio

L'analisi delle opportunità di arbitraggio evidenzia la presenza di un numero significativo di finestre temporali in cui il differenziale di prezzo tra mercati è positivo e potenzialmente sfruttabile.

In particolare:

- Le finestre hanno una durata media compresa tra 200 e 300 millisecondi.
- Il gap medio per unità è compreso tra 0.05 e 0.08 EUR.
- Il numero di finestre è proporzionale alla dimensione del dataset: SHELL presenta il numero più elevato di opportunità grazie alla maggiore quantità di dati disponibili.

Un risultato particolarmente rilevante è la distribuzione simmetrica delle opportunità tra le due direzioni (vendita su un mercato e acquisto sull'altro, e viceversa). Questo indica l'assenza di bias sistematici nella simulazione, suggerendo che le inefficienze generate sono di natura puramente stocastica e non strutturale.

Dal punto di vista economico, questo è coerente con mercati efficienti, in cui le opportunità di arbitraggio emergono temporaneamente ma non persistono in una direzione specifica.

4.3 Performance della Strategia di Trading

La simulazione dell'esecuzione delle strategie di arbitraggio mostra risultati coerenti tra i diversi titoli analizzati.

In particolare:

- Il profitto lordo aggregato varia significativamente tra i titoli, riflettendo la diversa frequenza delle opportunità.
- Il profitto netto, dopo costi di transazione e buffer di rischio, si attesta intorno al 37%-38% del profitto lordo.

Questo risultato è particolarmente significativo, in quanto indica che:

- I costi di transazione e il rischio di esecuzione assorbono circa il 60% del valore teorico dell'arbitraggio.
- La strategia rimane comunque profittevole, ma con margini ridotti, in linea con quanto osservato nei mercati ad alta frequenza.

La stabilità del margine netto tra diversi asset suggerisce che il modello di costo e rischio implementato è coerente e ben calibrato.

4.4 Limiti del Modello

Nonostante i risultati complessivamente positivi, emergono alcuni limiti strutturali:

- La bassa variabilità dello spread implica una distribuzione delle opportunità troppo uniforme rispetto alla realtà.
- L'assenza di shock estremi e dinamiche di volatilità clusterizzata riduce la presenza di eventi ad alto profitto.
- La simulazione delle venue non incorpora pienamente effetti di latenza e competizione tra operatori, tipici dei contesti HFT reali.

Questi elementi suggeriscono che il modello rappresenta una buona approssimazione di primo livello, ma richiede ulteriori estensioni per catturare completamente la complessità della microstruttura di mercato.

4.5 Conclusione

In sintesi, i risultati mostrano che il framework proposto è in grado di:

- Riprodurre realisticamente i principali indicatori di mercato (prezzi, volatilità, spread medio);
- Identificare e modellare in modo coerente le opportunità di arbitraggio;
- Simulare strategie di trading con performance economiche plausibili.

Tuttavia, il modello rimane una rappresentazione semplificata della realtà. L'integrazione di dinamiche più complesse, come la variabilità dello spread e gli effetti di latenza, rappresenta una direzione naturale per sviluppi futuri.